

Principal Components Analysis

Descripción del Dataset

El dataset [Breast Cancer Wisconsin \(Diagnostic\)](#) pertenece al área médica y se utiliza para la detección de cáncer de mama.

El objetivo del dataset es clasificar tumores como:

- 0 = Maligno
- 1 = Benigno

Los datos fueron obtenidos a partir de imágenes digitalizadas de muestras tomadas mediante biopsia (Fine Needle Aspiration).

El dataset contiene 30 variables predictoras numéricas. Estas variables describen características de las células, como:

- Radio
- Textura
- Perímetro
- Área
- Suavidad
- Compacidad
- Concavidad
- Simetría
- Dimensión fractal

Cada una de estas características se calcula en tres versiones:

- Promedio (mean)
- Error estándar (se)
- Pior valor observado (worst)

En total, el dataset contiene 569 observaciones.

```
In [5]: import pandas as pd

df = pd.read_csv("data.csv")

Out[5]:
```

	id	diagnosis	radius_mean	texture_mean	perimeter_mean	area_mean	smoothness_mean	compactness_mean	concavity_mean	concave point_mean	...	radius_worst	texture_worst	perimeter_worst	area_worst	smoothness_worst	compactness_worst	concavity_worst	concave point_worst
0	842302	M	17.99	10.38	122.80	1001.0	0.11840	0.27760	0.3001	0.14710	...	17.33	184.60	2019.0	0.1622	0.6606	0.71		
1	842517	M	20.57	17.77	132.90	1326.0	0.08474	0.07864	0.0869	0.07017	...	23.41	158.80	1956.0	0.1238	0.1866	0.24		
2	84300303	M	19.69	21.25	130.00	1203.0	0.10960	0.15990	0.1974	0.12790	...	25.53	152.50	1709.0	0.1444	0.4245	0.45		
3	84348301	M	11.42	20.38	77.58	386.1	0.14250	0.28390	0.2414	0.10520	...	26.50	98.87	567.7	0.2098	0.8863	0.68		
4	84384602	M	20.29	14.54	135.10	1297.0	0.10030	0.13280	0.1980	0.10430	...	16.67	152.20	1575.0	0.1374	0.2050	0.40		

5 rows × 33 columns

Limpieza de datos

El conjunto de datos contiene una columna de identificación ("id") que no proporciona información predictiva. Además, el conjunto de datos incluye una columna vacía ("Sin número: 32") que solo contiene valores faltantes.

Estas columnas se eliminarán, ya que no contribuyen a la tarea de clasificación.

```
In [6]: df.columns

df = df.drop(columns=["id", "Unnamed: 32"])

df.head()
```

```
Out[6]:
```

	diagnosis	radius_mean	texture_mean	perimeter_mean	area_mean	smoothness_mean	compactness_mean	concavity_mean	concave point_mean	symmetry_mean	...	radius_worst	texture_worst	perimeter_worst	area_worst	smoothness_worst	compactness_worst	concavity_worst	concave point_worst
0	M	17.99	10.38	122.80	1001.0	0.11840	0.27760	0.3001	0.14710	0.2419	...	25.38	17.33	184.60	2019.0	0.1622	0.6606	0.71	
1	M	20.57	17.77	132.90	1326.0	0.08474	0.07864	0.0869	0.07017	0.1812	...	24.99	23.41	158.80	1956.0	0.1238	0.1866	0.24	
2	M	19.69	21.25	130.00	1203.0	0.10960	0.15990	0.1974	0.12790	0.2069	...	23.57	25.53	152.50	1709.0	0.1444	0.4245	0.45	
3	M	11.42	20.38	77.58	386.1	0.14250	0.28390	0.2414	0.10520	0.2597	...	14.91	26.80	98.87	567.7	0.2098	0.8863	0.68	
4	M	20.29	14.54	135.10	1297.0	0.10030	0.13280	0.1980	0.10430	0.1809	...	22.54	16.67	152.20	1575.0	0.1374	0.2050	0.40	

5 rows × 31 columns

Ahora verificamos si el conjunto de datos contiene valores faltantes.

```
In [7]: df.isnull().sum()

Out[7]:
```

	diagnosis	radius_mean	texture_mean	perimeter_mean	area_mean	smoothness_mean	compactness_mean	concavity_mean	concave point_mean	symmetry_mean	...	radius_worst	texture_worst	perimeter_worst	area_worst	smoothness_worst	compactness_worst	concavity_worst	concave point_worst
0	M	17.99	10.38	122.80	1001.0	0.11840	0.27760	0.3001	0.14710	0.2419	...	25.38	17.33	184.60	2019.0	0.1622	0.6606	0.71	
1	M	20.57	17.77	132.90	1326.0	0.08474	0.07864	0.0869	0.07017	0.1812	...	24.99	23.41	158.80	1956.0	0.1238	0.1866	0.24	
2	M	19.69	21.25	130.00	1203.0	0.10960	0.15990	0.1974	0.12790	0.2069	...	23.57	25.53	152.50	1709.0	0.1444	0.4245	0.45	
3	M	11.42	20.38	77.58	386.1	0.14250	0.28390	0.2414	0.10520	0.2597	...	14.91	26.80	98.87	567.7	0.2098	0.8863	0.68	
4	M	20.29	14.54	135.10	1297.0	0.10030	0.13280	0.1980	0.10430	0.1809	...	22.54	16.67	152.20	1575.0	0.1374	0.2050	0.40	

5 rows × 31 columns

La variable objetivo "diagnosis" es categórica (M = Maligno, B = Benigno). Se codificará como:

M → 0 B → 1

Esta codificación convierte el problema en una tarea de clasificación binaria.

```
In [8]: df["diagnosis"] = df["diagnosis"].map({"M": 0, "B": 1})

df.head()
```

```
Out[8]:
```

	diagnosis	radius_mean	texture_mean	perimeter_mean	area_mean	smoothness_mean	compactness_mean	concavity_mean	concave point_mean	symmetry_mean	...	radius_worst	texture_worst	perimeter_worst	area_worst	smoothness_worst	compactness_worst	concavity_worst	concave point_worst
0	0	17.99	10.38	122.80	1001.0	0.11840	0.27760	0.3001	0.14710	0.2419	...	25.38	17.33	184.60	2019.0	0.1622	0.6606	0.71	
1	0	20.57	17.77	132.90	1326.0	0.08474	0.07864	0.0869	0.07017	0.1812	...	24.99	23.41	158.80	1956.0	0.1238	0.1866	0.24	
2	0	19.69	21.25	130.00	1203.0	0.10960	0.15990	0.1974	0.12790	0.2069	...	23.57	25.53	152.50	1709.0	0.1444	0.4245	0.45	
3	0	11.42	20.38	77.58	386.1	0.14250	0.28390	0.2414	0.10520	0.2597	...	14.91	26.80	98.87	567.7	0.2098	0.8863	0.68	
4	0	20.29	14.54	135.10	1297.0	0.10030	0.13280	0.1980	0.10430	0.1809	...	22.54	16.67	152.20	1575.0	0.1374	0.2050	0.40	

5 rows × 31 columns

Análisis de datos

Es importante conocer cuántos casos son benignos y cuántos malignos, ya que esto nos permite entender si el dataset está balanceado.

```
In [9]: df["diagnosis"].value_counts()

Out[9]:
```

diagnosis	count
1	357
0	212

dtype: int64

Se observa que el dataset contiene más casos benignos que malignos.

Sin embargo, la diferencia no es extremadamente grande, por lo que el dataset puede considerarse razonablemente balanceado.

Ahora visualizamos la distribución de la variable objetivo mediante una gráfica.

```
In [10]: import matplotlib.pyplot as plt

df["diagnosis"].value_counts().plot(kind="bar")

plt.title("Distribución de Tumores")
plt.xlabel("diagnosis (0 = Maligno, 1 = Benigno)")
plt.ylabel("Cantidad")
plt.show()
```

A continuación observamos estadísticas descriptivas de las variables predictoras.

Esto nos permite entender la escala y variabilidad de los datos.

```
In [11]: df.describe()

Out[11]:
```

	diagnosis	radius_mean	texture_mean	perimeter_mean	area_mean	smoothness_mean	compactness_mean	concavity_mean	concave point_mean	symmetry_mean	...	radius_worst	texture_worst	perimeter_worst	area_worst	smoothness_worst	compactness_worst	concavity_worst	concave point_worst
count	569.000000	569.000000	569.000000	569.000000	569.000000	569.000000	569.000000	569.000000	569.000000	569.000000	...	569.000000	569.000000	569.000000	569.000000	569.000000	569.000000	569.000000	569.000000
mean	0.627417	14.127292	19.288649	91.969033	654.889104	0.096360	0.104341	0.088799	0.048919	0.181162	...	16.269190	25.677223	107.261213	860.583128	0.132369	0.532369	0.229332	0.132369
std	0.469316	3.324048	4.301036	24.286981	351.954129	0.014064	0.020913	0.079720	0.038003	0.027414	...	4.833242	6.146258	33.602542	569.356993	0.022932	0.022932	0.022932	0.022932
min	0.000000	6.981000	9.710000	43.790000	143.500000	0.052630	0.019080	0.000000	0.000000	0.000000	...	7.930000	12.020000	50.410000	186.200000	0.071170	0.071170	0.071170	0.071170
25%	0.000000	11.700000	16.710000	75.170000	420.300000	0.066370	0.064920	0.023960	0.020310	0.161900	...	13.010000	21.080000	84.110000	519.300000	0.116600	0.116600	0.116600	0.116600
50%	1.000000	13.570000	18.840000	86.240000	551.100000	0.056870	0.062630	0.061540	0.033500	0.179200	...	14.970000	25.410000	97.640000	686.500000	0.131300	0.131300	0.131300	0.131300
75%	1.000000	15.760000	21.800000	104.100000	782.700000	0.105300	0.130400	0.130700	0.074000	0.198700	...	18.790000	29.720000	128.400000	1084.000000	0.146000	0.146000	0.146000	0.146000
max	1.000000	28.110000	39.280000	188.500000	2501.000000	0.163400	0.345400	0.426800	0.201200	0.304000	...	36.040000	49.540000	251.200000	4254.000000	0.222600	0.222600	0.222600	0.222600

8 rows × 31 columns

Se observa que las variables tienen escalas muy diferentes.

Por ejemplo, algunas variables como "area_mean" tienen valores mucho mayores que otras como "smoothness_mean".

Es necesario estandarizar los datos antes de aplicar PCA, ya que PCA es sensible a la escala.

Ahora analizamos la correlación entre variables.

```
In [12]: import seaborn as sns

plt.figure(figsize=(10,8))
sns.heatmap(df.drop("diagnosis", axis=1).corr(), cmap="coolwarm")

plt.title("Matriz de Correlación")
plt.show()
```

Se observan correlaciones fuertes entre varias variables.

Por ejemplo, variables relacionadas con área, perímetro y radio presentan alta correlación.

Esto indica que existe redundancia en el dataset.

Estandarización de los datos

Es necesario estandarizar las variables predictoras.

Si una variable tiene valores mucho más grandes que otras, puede dominar el análisis y generar resultados incorrectos.

Por esta razón, transformamos cada variable para que tenga:

- Media igual a 0
- Desviación estándar igual a 1

```
In [13]: from sklearn.preprocessing import StandardScaler

X = df.drop("diagnosis", axis=1) # Variables predictoras y variable objetivo
y = df["diagnosis"]

scaler = StandardScaler() # Estandarización
X_scaled = scaler.fit_transform(X)

X_scaled = pd.DataFrame(X_scaled, columns=X.columns)

X_scaled.head()
```

```
Out[13]:
```

	radius_mean	texture_mean	perimeter_mean	area_mean	smoothness_mean	compactness_mean	concavity_mean	concave point_mean	symmetry_mean	fractal_dimension_mean	...	radius_worst	texture_worst	perimeter_worst	area_worst	smoothness_worst	compactness_worst	concavity_worst	concave point_worst
0	1.09764	-2.07335	1.269934	0.984375	1.568466	3.283515	2.652874	2.502476	2.217515	2.255747	...	1.886690	-1.369293	2.303601	2.001237	1.307896	0.000000	0.000000	0.000000
1	1.826921	-0.352632	1.858955	1.908708	-0.482692	-0.487072	-0.023846	0.548144	0.001392	-0.868652	...	1.805927	-0.369203	1.535126	1.896489	-0.375612	0.000000	0.000000	0.000000
2	1.578888	0.455187	1.566053	1.558884	0.942210	1.052626	1.363474	2.037231	0.936885	-0.398008	...	1.511870	-0.033974	1.347475	1.456285	0.527407	0.000000	0.000000	0.000000
3	-0.786909	0.252732	-0.950687	-0.764464	0.283553	3.402399	1.915879	1.451707	2.867383	-0.910919	...	-0.281664	0.123984	-0.249939	-0.550021	3.394275	0.000000	0.000000	0.000000
4	1.750297	-1.151816	1.776673	1.826229	0.280372	0.530940	1.371011	1.428493	-0.009660	-0.262450	...	1.296575	-1.466770	1.338539	1.220724	0.220566	0.000000	0.000000	0.000000

5 rows × 30 columns

Después de la estandarización, todas las variables tienen media cercana a 0 y su desviación estándar igual a 1.

Esto asegura que ninguna variable tenga mayor influencia simplemente por tener valores más grandes.

Matriz de covarianza

Valores positivos indican que dos variables aumentan juntas. Valores negativos indican que cuando una aumenta, la otra disminuye.

```
In [14]: import numpy as np

cov_matrix = np.cov(X_scaled.T)

cov_matrix[:5, :5]
```

```
Out[14]:
```

array([[1.00176856, 0.22430105, 0.89981207, 0.48800584, 0.17088051],
[0.22430105, 1.00176856, 0.33011322, 0.30365059, 0.22342599],
[0.89981207, 0.33011322, 1.00176856, 0.98843451, 0.20764309],
[0.48800584, 0.30365059, 0.98843451, 1.00176856, 0.17780501],
[0.17088051, -0.22430105, 0.20764309, 0.17780501, 1.00176856])

La matriz de covarianza muestra cómo se relacionan las variables entre sí.

Se observan valores altos cercanos a 1, lo que indica que varias variables están fuertemente relacionadas.

Esto significa que existe redundancia en el dataset.

Por esta razón, PCA es útil, ya que puede reducir el número de variables sin perder demasiada información.

Eigenvalores y Eigenvectores

Los eigenvalores representan las nuevas direcciones del espacio. Estas direcciones se llaman componentes principales.

Los eigenvectores indican cuánta varianza explica cada componente principal.

El componente con mayor eigenvalor será el componente principal número 1 (PC1).

```
In [15]: eigenvalores, eigenvectores = np.linalg.eig(cov_matrix)

eigenvalores[:10]
```

```
Out[15]:
```

array([12.30499079, 5.7013746 , 2.82231016, 1.98412732, 1.65183324,
1.20548254, 0.47640888, 0.47745625, 0.43732878, 0.33110877],
dtype=float64)

Los eigenvalores indican cuánta varianza explica cada componente principal.

El primer eigenvalor (12.30) es mucho mayor que los demás, lo que significa que el primer componente principal captura gran parte de la información del dataset.

Los valores disminuyen progresivamente, lo que indica que los primeros componentes son los más importantes.

Esto sugiere que podemos reducir dimensiones manteniendo solo los primeros componentes principales.