UNIVERSIDAD DE MONTERREY

Tarea 3: Principal Components Analysis

Inteligencia Artificial II

Dr. Eduardo Martinez Escobedo

Autor:

Ramón Lerma Hdz. | 636525 IMA

None

```
07 de Marzo del 2026, San Pedro Garza García, N.L.
```

Código de Honor: “Doy mi palabra que he realizado esta actividad con integridad académica.”

Dataset Source:

This dataset was obtained from Kaggle: Breast Cancer Wisconsin (Diagnostic) Dataset https://www.kaggle.com/datasets/uciml/breast-cancer-wisconsin-data

1.-

```python
import pandas as pd

df = pd.read_csv("data.csv")
df.head()
```

¿Qué debo entender de esta tabla?

	id	diagnosis	radius_mean	texture_mean	perimeter_mean	area_mean	smoothness_mean	compactness_mean	concavity_mean	concave points_mean	...	texture_worst	perimeter_worst	area_worst	smoothness_worst	compactness_worst	concavity_wo
0	842302	M	17.99	10.38	122.80	1001.0	0.11840	0.27760	0.3001	0.14710	...	17.33	184.60	2019.0	0.1622	0.6656	0.71
1	842517	M	20.57	17.77	132.90	1326.0	0.08474	0.07864	0.0869	0.07017	...	23.41	158.80	1956.0	0.1238	0.1866	0.24
2	84300903	M	19.69	21.25	130.00	1203.0	0.10960	0.15990	0.1974	0.12790	...	26.53	162.50	1709.0	0.1444	0.4245	0.45
3	84348301	M	11.42	20.38	77.58	386.1	0.14250	0.28390	0.2414	0.10520	...	26.50	98.87	567.7	0.2098	0.8663	0.68
4	84358402	M	20.29	14.34	135.10	1297.0	0.10030	0.13280	0.1980	0.10430	...	16.67	152.20	1575.0	0.1374	0.2050	0.40

5 rows × 33 columns

Interpretación de la tabla

La tabla muestra una vista previa del conjunto de datos. Cada fila representa a un paciente y cada columna representa una característica medida del tumor.

El conjunto de datos tiene 33 columnas en total. Sin embargo, la función df.head() solo presenta las primeras 5 filas para observar cómo están organizados los datos.

La columna id es solo un identificador del paciente y no aporta información útil para el modelo de predicción.

La columna diagnosis indica el diagnóstico del tumor:

M --> significa maligno.

B --> significa benigno.

Esta es la variable objetivo.

Las demás columnas contienen mediciones numéricas del tumor obtenidas de imágenes médicas, como por ejemplo:

radius_mean: promedio del radio del tumor.

texture_mean: medida de la textura o irregularidad del tumor.

perimeter_mean: perímetro promedio del tumor.

area_mean: área promedio del tumor.

smoothness_mean: qué tan suave es la superficie del tumor.

compactness_mean: nivel de compactación del tumor.

concavity_mean: medida de la concavidad de la forma del tumor.

concave_points_mean: número de puntos donde la superficie del tumor presenta curvaturas hacia adentro.

Estas variables describen características geométricas y estructurales del tumor. Se utilizan como variables de entrada del modelo para identificar patrones que distingan entre tumores malignos y benignos.

2.-

Análisis de datos

Es importante conocer cuántos casos son benignos y cuántos malignos, ya que esto nos permite entender si el dataset está balanceado

```
df["diagnosis"].value_counts()
```

diagnosis	count
1	357
0	212

dtype: int64

Se observa que el dataset contiene más casos benignos que malignos.

Sin embargo, la diferencia no es extremadamente grande, por lo que el dataset puede considerarse razonablemente ~~balanceado~~.

Ahora visualizamos la distribución de la variable objetivo mediante una gráfica.

El dataset tiene 357 casos de una clase y 212 de la otra. Esto muestra que la variable objetivo no está completamente equilibrada, ya que una clase tiene más muestras que la otra.

Esto significa que el modelo podría favorecer la clase mayoritaria durante el entrenamiento. Esto podría llevar a resultados engañosos si solo se mide el desempeño con la exactitud.

Por esta razón, al trabajar con datasets desbalanceados, es importante mirar otras métricas de evaluación, como precisión, recuperación y especialmente el F1-score.

El F1-score es una métrica que combina precisión y recuperación mediante su media armónica. Esto permite obtener una medida más equilibrada del desempeño del modelo, sobre todo cuando las clases no tienen la misma cantidad de muestras.

Así, usar el F1-score ayuda a evaluar mejor qué tan bien el modelo identifica correctamente cada clase del problema.

3.-

11:

	diagnosis	radius_mean	texture_mean	perimeter_mean	area_mean	smoothness_mean	compactness_mean	concavity_mean	concave points_mean
count	569.000000	569.000000	569.000000	569.000000	569.000000	569.000000	569.000000	569.000000	569.000000
mean	0.627417	14.127292	19.289649	91.969033	654.889104	0.096360	0.104341	0.088799	0.048919
std	0.483918	3.524049	4.301036	24.298981	351.914129	0.014064	0.052813	0.079720	0.038803
min	0.000000	6.981000	9.710000	43.790000	143.500000	0.052630	0.019380	0.000000	0.000000
25%	0.000000	11.700000	16.170000	75.170000	420.300000	0.086370	0.064920	0.029560	0.020310
50%	1.000000	13.370000	18.840000	86.240000	551.100000	0.095870	0.092630	0.061540	0.033500
75%	1.000000	15.780000	21.800000	104.100000	782.700000	0.105300	0.130400	0.130700	0.074000
max	1.000000	28.110000	39.280000	188.500000	2501.000000	0.163400	0.345400	0.426800	0.201200

8 rows × 31 columns

Se observa que las variables tienen escalas muy diferentes. ¿Con qué valores?

Por ejemplo, algunas variables como "area_mean" tienen valores mucho mayores que otras como "smoothness_mean".

Es necesario estandarizar los datos antes de aplicar PCA, ya que PCA es sensible a la escala.

Ahora analizamos la correlación entre variables.

Análisis de estadísticas descriptivas

Las estadísticas descriptivas obtenidas con df.describe() muestran que las variables del conjunto de datos tienen escalas muy diferentes.

Por ejemplo, area_mean tiene un promedio de 654.89 y un valor máximo de 2501.00, mientras que smoothness_mean tiene un promedio de 0.096 y un máximo de 0.163.

Esto indica que algunas variables tienen valores mucho más grandes que otras. Debido a estas diferencias de escala, es necesario estandarizar los datos antes de aplicar PCA, ya que este método es sensible a la magnitud de las variables.

area_mean	sm
569.000000	
654.889104	
351.914129	
143.500000	
420.300000	
551.100000	
782.700000	
2501.000000	

smoothness_mean	compa
569.000000	
0.096360	
0.014064	
0.052630	
0.086370	
0.095870	
0.105300	
0.163400	

4.-

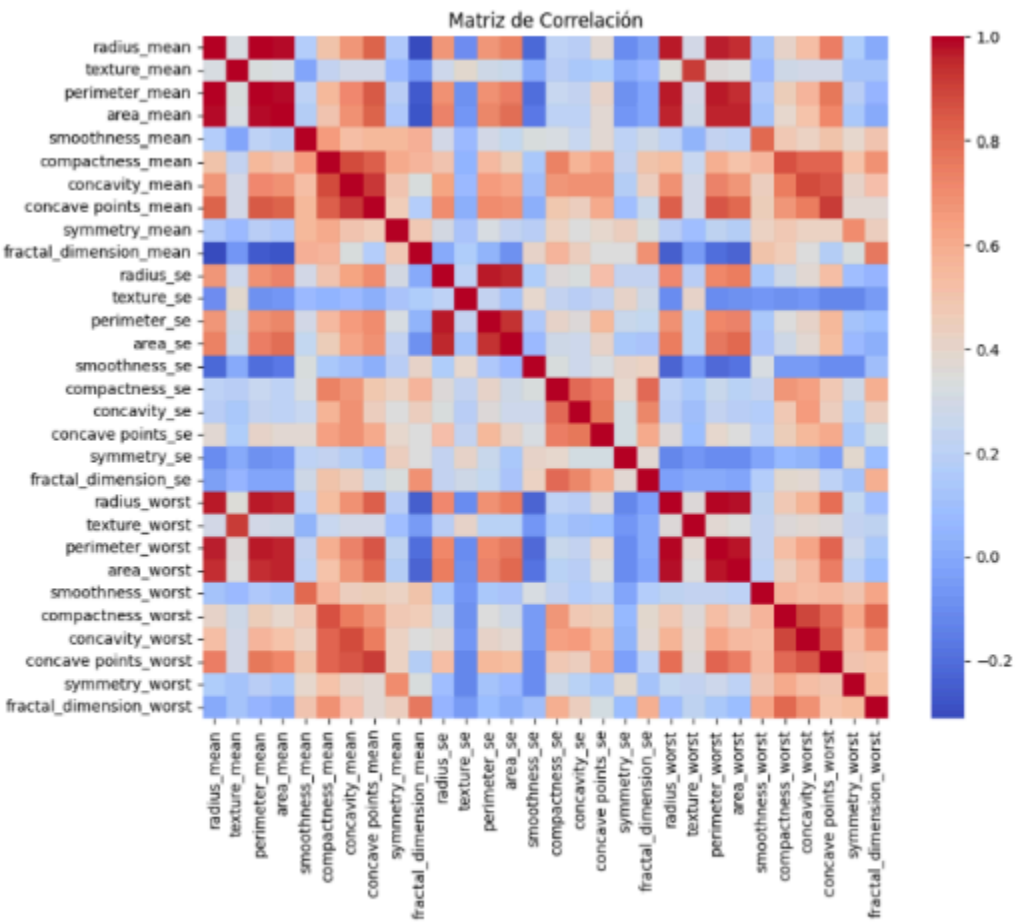

Se observan correlaciones fuertes entre varias variables.

Por ejemplo, variables relacionadas con área, perímetro y radio presentan alta correlación.

¿de cuánto? x

Esto indica que existe redundancia en el dataset.

En la matriz de correlación se observan correlaciones fuertes entre varias variables. Por ejemplo, radius_mean, perimeter_mean y area_mean presentan correlaciones muy altas, cercanas a 0.99. Esto indica que estas variables están fuertemente relacionadas y contienen información muy similar.

La presencia de estas correlaciones altas sugiere que existe redundancia en el dataset, lo cual justifica el uso de Análisis de Componentes Principales (PCA) para reducir la dimensionalidad y eliminar información repetida entre las variables.

5.-

```python
from sklearn.preprocessing import StandardScaler

X = df.drop("diagnosis", axis=1) # Variables predictoras y variable objetivo
y = df["diagnosis"]

scaler = StandardScaler() # Estandarización
X_scaled = scaler.fit_transform(X)

X_scaled = pd.DataFrame(X_scaled, columns=X.columns)

X_scaled.head()
```

	radius_mean	texture_mean	perimeter_mean	area_mean	smoothness_mean	compactness_mean	concavity_mean	concave points_mean	symmetry_mean	fractal_dimer
0	1.097064	-2.073335	1.269934	0.984375	1.568466	3.283515	2.652874	2.532475	2.217515	
1	1.829821	-0.353632	1.685955	1.908708	-0.826962	-0.487072	-0.023846	0.548144	0.001392	
2	1.579888	0.456187	1.566503	1.558884	0.942210	1.052926	1.363478	2.037231	0.939685	
3	-0.768909	0.253732	-0.592687	-0.764464	3.283553	3.402909	1.915897	1.451707	2.867383	
4	1.750297	-1.151816	1.776573	1.826229	0.280372	0.539340	1.371011	1.428493	-0.009560	

5 rows × 30 columns

¿Dónde se confirma? X

Después de la estandarización, todas las variables tienen media cercana a 0 y desviación estándar igual a 1.

Esto asegura que ninguna variable tenga mayor influencia simplemente por tener valores más grandes.

Después de aplicar StandardScaler, las variables fueron estandarizadas para que tengan media aproximadamente igual a 0 y desviación estándar cercana a 1. Esto puede verificarse calculando las estadísticas del conjunto transformado, donde las medias de las variables son cercanas a cero y las desviaciones estándar cercanas a uno.

La estandarización es un paso importante antes de aplicar PCA, ya que este método es sensible a la escala de las variables. Al estandarizar los datos se evita que las variables con valores más grandes tengan mayor influencia en el análisis.

```python
X_scaled.describe().loc[['mean','std']]
```

	radius_mean	texture_mean	perimeter_mean	area_mean	smoothness_mean	compactness_mean	concavity_mean	concave points_mean	symmetry_mean	fra
mean	-1.373633e-16	6.868164e-17	-1.248757e-16	-2.185325e-16	-8.366672e-16	1.873136e-16	4.995028e-17	-4.995028e-17	1.748260e-16	
std	1.000880e+00	1.000880e+00	1.000880e+00	1.000880e+00	1.000880e+00	1.000880e+00	1.000880e+00	1.000880e+00	1.000880e+00	

2 rows × 30 columns

```
X_scaled.describe().loc[['mean','std']]
```

ure_worst	perimeter_worst	area_worst	smoothness_worst	compactness_worst	concavity_worst	concave points_worst	symmetry_worst	fractal_dimension_worst
48757e-17	-3.746271e-16	0.00000	-2.372638e-16	-3.371644e-16	7.492542e-17	2.247763e-16	2.622390e-16	-5.744282e-16
00880e+00	1.000880e+00	1.00088	1.000880e+00	1.000880e+00	1.000880e+00	1.000880e+00	1.000880e+00	1.000880e+00